

《智能体应用开发实践》结课报告

作品名称：智能项目计划书（申报类文档）生成系统 **应用平台：**自建平台（Streamlit + 阿里云百炼兼容接口 + ChromaDB）**学院：**信息技术学院 **专业：**人工智能与大模型技术应用微专业 **班级：**微专业01班 **学号：**

请填写

姓名：

请填写

总分：

请填写

任课教师：

请填写

2026年4月30日

摘要

本项目面向政府与企业科技类申报、基金说明书及合规披露类文档撰写场景，解决传统撰写中多格式资料检索难、纯大模型生成易产生合规幻觉、长文档一次性生成不可控以及交付物必须为可编辑Word定稿的痛点。目标用户为机构资料管理员、模板管理员及专业撰稿人。

系统综合运用了大模型角色设定、RAG（检索增强生成） workflow、向量数据库、本地知识库及外部联网插件调用等核心能力。系统通过解析多格式文件构建向量知识库，利用锚点与小模型双重策略分析Word模板结构，生成“填空任务”列表；随后基于RAG workflow按段落或表格单元格粒度逐段生成正文，并在知识库薄弱时自动调用百炼内置联网搜索插件补料；最终通过结构化回填技术将内容写入Word导出。

最终成果为一个可本地部署的Streamlit Web应用，实现了“资料入库—模板分析—分段RAG生成—联网补料—Word导出”的完整业务闭环。典型演示效果显示，系统在保持原文格式不变的前提下，能精准回填长文本与复杂表格，并通过可配置的路由元数据日志与审核Agent保障了生成内容的可追溯性与合规性。创新点在于细粒度的填空任务模型与基于相似度阈值的智能联网路由机制，不足在于对无文本层PDF的解析依赖外部OCR，以及顺序生成的效率有待提升。

关键词：智能体应用；角色设定；RAG workflow；知识库；向量数据库；插件调用；大模型应用开发

第1章 项目选题与需求分析

1.1 项目背景与问题来源

在政府及企业的日常运营中，项目计划书、基金说明书、风险评估表等申报类文档的撰写是一项高频且严谨的工作。此类文档版式固定、章节重复性高，但事实与合规约束极严，机构全称、产品代码、费率区间、监管状态等必须与底稿一致。当前现状是，机构内部材料分散在Word、PDF、PPT及截图中，缺乏统一检索入口；纯大模型“从零撰写”极易产生与机构材料不一致的幻觉；而完全依赖人工从多份文档中摘抄则周期长、易遗漏。智能体的介入价值在于，通过RAG技术将分散资料沉淀为向量知识库，按模板结构分段生成，既利用了大模型的组织表达能力，又通过检索约束杜绝了关键事实的杜撰，最终通过结构化回填直接输出Word定稿，大幅缩短初稿周期并提高可追溯性。本项目的边界明确为辅助起草与结构化回填，不涉及自动合规裁决与电子签章，法定责任仍由人工复核承担。

1.2 目标用户与应用场景

目标用户主要分为三类。第一类是资料管理员，其典型需求是将多份产品说明书PDF与内部Word一并入库以便统一检索，使用场景为系统后端的资料维护与质量清理，预期输出为结构化的向量库与来源清单。第二类是模板管理员，其需求是维护法务合规提供的docx模板，确保关键条款处使用特定锚点（如{{RISK_DISCLOSURE}}）避免大模型误判，使用场景为模板上传与结构验证，预期输出为可供生成器调用的任务列表。第三类是专业撰稿人，其需求是在“增强”模式下放宽检索距离、提高字数上限以获得充实初稿，同时保留流式阅读体验，使用场景为日常高频的文档起草，预期输出为可直接下载且格式完善的Word成稿。

1.3 功能目标与演示目标

本项目的功能目标可细化为五个模块。模块一为智能问答与咨询，基于角色设定与知识库回答用户关于资料内容的提问；模块二为流程办理与任务规划，通过工作流分步骤完成模板分析与分段生成任务；模块三为数据记录与查询，把用户上传的资料解析后写入向量数据库，并支持按来源查询与移除；模块四为外部工具调用，在知识库薄弱时调用百炼内置联网搜索插件获取实时信息；模块五为综合演示，组合上述能力完成从入库到Word导出的完整业务闭环。验收方式以端到端的Word成稿质量、回填位置准确性及日志可解释性为准。

第2章 智能体总体设计

2.1 应用总体架构

系统采用分层架构设计。最上层为表现层，基于Streamlit构建侧栏与三标签页交互界面；应用编排层负责管理会话状态、模式冲刷及模板签名缓存；领域服务层是核心，包含模板分析器、RAG内容生成器、Word回填器、审核代理及注册表服务；基础设施层则由ChromaDB持久化向量库、OpenAI兼容客户端及环境配置组成。数据流向遵循“用户输入—意图与结构识别—知识库检索—联网路由判断—工作流分段生成—审核修订—数据库记录—Word回填输出”的完整链路。

2.2 智能体角色设定

智能体名称为“资深申报撰写专家”。角色身份定位于政府及企业科技类申报、合规披露类文档的专业起草助手。服务对象为具备一定业务知识但急需提升撰写效率的机构人员。核心任务包括：依据检索到的机构事实资料撰写段落、按字数与格式要求填充表格单元格、在缺乏依据时显式声明而非杜撰、严格遵循Word模板结构进行回填。语气风格为专业、严谨、客观、克制，符合合规披露语体。能力边界明确：不确定的事实在无联网支撑时必须声明“依据现有资料暂无明确信息”，不代替人工进行法律合规裁决。输出格式要求纯文本输出，严禁使用Markdown符号，表格单元格需简明扼要。

2.3 任务边界、安全约束与交互策略

在事实准确性方面，涉及价格、费率、监管状态等敏感信息时，若检索相似度低于阈值，系统将提示“该信息可能变化，请以官方通知为准”并尝试联网补料。在任务边界方面，系统明确告知用户“我可以帮你整理方案与填充模板，但不能代替人工审核与签章”。在隐私保护方面，系统不要求用户提供身份证号等敏感信息，且API密钥仅通过环境变量注入，不写入日志明文。在交互澄清方面，当用户未上传模板或知识库为空时，系统会提出关键澄清问题，如“请先在知识库管理中入库相关资料，并上传Word模板”。

第3章 核心能力实现过程

3.1 提示词与角色工程

提示词经历了三个版本的迭代。V1版本仅设定了资深撰写专家的身份，导致回答泛化且常出现Markdown格式；V2版本加入了任务流程与纯文本输出格式约束，解决了格式污染问题，但结构仍不稳定；V3版本整合了知识库/联网调用规则与安全约束，最终版进一步加入了表格上下文与审核纠错策略，大幅提高了可演示性与稳定性。最终版提示词要求智能体必须基于检索到的证据片段撰写，若证据为空或相似度极低，需在段落末尾显式标注；同时针对表格任务，提示词强制约束输出单格简短内容，禁止跨格输出。

3.2 workflow设计与节点配置

workflow实现了自动化的分段生成与回填处理。节点1为用户输入，接收模板与配置参数；节点2为意图与结构识别，优先扫描锚点，无锚点时调用小模型

(SMALL_LLM_MODEL)解析模板结构为JSON任务列表；节点3为知识库检索，基于任务章节与描述构造查询语句，按top_k与最大距离阈值过滤弱相关片段；节点4为联网路由判断，当知识库为空或最佳命中相似度低于0.3时，切换至联网档模型并启用enable_search；节点5为内容生成，大模型依据证据流式输出纯文本；节点6为审核与回填，审核Agent对内容进行规则与模型质检，通过后由WordFiller按锚点或表格索引回填。

3.3 数据库设计与数据管理

本项目采用ChromaDB作为向量数据库，辅以本地JSON文件作为知识库注册表。向量库的集合名规则为plan_kb_{slug}，用于隔离不同项目的语料。核心数据表包括知识库注册表与向量片段集合。注册表记录知识库的唯一标识与展示名称；向量片段集合存储文本向量及元数据，元数据包含source（来源文件名）、chapter（章节）与type（类型）。系统能够

按来源一键移除旧片段并重新入库，支持增量更新。演示中可清晰展示同一来源文件再次入库时，旧数据被清理、新分块写入的完整过程。

3.4 知识库建设与检索验证

知识库资料主要来源于机构历史文档、产品说明PDF及内部培训Word。处理方式上，系统通过多格式解析器提取文本层，对图片走视觉大模型提取描述；随后采用滑动窗口分块策略（单块约700字，重叠120字）进行切分，减少语义断裂。在项目中的作用是为生成器提供事实依据，杜绝幻觉。测试表明，对于直接命中章节标题的问题，系统能准确返回对应片段；对于口语化提问，系统通过查询扩展与语义检索也能较好地命中相关段落；但对于表格内部数据的精确查询，若分块时未保留表格上下文，检索效果存在衰减，需通过后续的表格上下文注入机制优化。

3.5 插件调用与外部能力扩展

本项目调用了阿里云百炼平台提供的内置联网搜索插件。调用目的在于解决知识库覆盖不足时仍需填写内容的痛点。输入参数为工作流构造的查询语句及用户开启联网的开关状态，输出结果为模型基于网络实时信息生成的补充内容。与工作流的连接方式为条件触发：当检索节点判定知识库薄弱或低相似时，生成节点将模型切换为支持联网的 VISION_WEB_MODEL，并在请求体中注入 `extra_body={"enable_search": True}`，同时关闭深度思考以降低耗时，从而实现无缝的本地知识与互联网知识融合。

3.6 多能力协同与异常处理

角色设定、工作流、数据库、知识库和插件的协同体现在一次完整的弱库生成任务中。用户请求生成后，工作流首先检索本地库，若未命中，角色设定约束模型不得杜撰，此时联网插件被触发补料，生成后审核Agent校验合规性，最终回填。异常处理方面：针对知识库未命中，策略是扩大检索或触发联网，优化后消除了无据杜撰现象；针对数据库写入失败，系统校验必填字段并返回可理解提示；针对插件调用失败，设置备用回答并提示稍后重试；针对回答幻觉，采用规则审核与模型质检双重校验，对major_issue级问题自动注入纠错提示重试生成。

第4章 运行演示、测试与效果分析

4.1 运行入口与演示环境

应用入口为本机Streamlit服务地址（如localhost:8501），运行平台为自建Web应用，演示设备为电脑端Chrome浏览器。演示无需特殊账号，但需在环境变量中配置百炼API Key。演示视频展示了从空白库到导出成稿的完整过程。

4.2 典型演示用例

TC01为基础咨询类问题，用户提问“产品A的费率结构是什么”，系统调用知识库准确返回依据并作答。TC02为复杂表格填充任务，系统通过LLM分析无锚点模板，提取表格行列索引，并结合表头上下文生成简短内容回填。TC03为联网补料任务，在空库状态下输

入“最新行业监管政策”，系统路由至联网模型，返回实时网络信息并在日志中标记 `native_web_search=True`。TC04为完整业务闭环，用户上传PDF入库、上传带锚点模板、选择增强模式生成，系统完成端到端任务并输出可下载的Word文档。

4.3 演示过程截图与结果分析

通过截图可见，用户输入后系统流式输出文本，日志面板清晰展示了路由元数据（包括 `kb_hits`、`best_similarity_est`、`model`等）。从准确性看，回答严格受限於知识库资料，未见关键数据幻觉；从完整性看，用户任务的全部环节包括表格均被覆盖；从稳定性看，多次测试在相同阈值下路由决策一致；从可解释性看，每段生成均附带了调用依据与路由日志；从交互体验看，流式输出与进度提示降低了等待焦虑。改进方向在于，部分复杂合并单元格的表格索引仍有极低概率错位，需后续优化LLM分析JSON的鲁棒性。

第5章 项目评价、创新与改进

5.1 项目完成度自评

本项目已完成全部核心功能。智能体具备明确角色设定与系统提示词；工作流可运行且包含检索、路由、生成、审核等关键节点；向量数据库能完成多格式资料的读写与来源管理；知识库能有效支撑分段生成；联网插件调用已集成并可通过界面观测；完整演示用例可端到端运行。报告材料完整，截图与日志清晰。

5.2 创新点与应用价值

创新点一是基于细粒度“填空任务”的Word结构化回填机制，区别于全文本生成，系统通过锚点扫描与LLM JSON分析，将长文档拆解为段落与单元格粒度的任务，实现了对Word格式的无损回填，极大提升了交付物的可用性。创新点二是智能联网路由与可解释日志，系统并未简单粗暴地全量联网，而是基于估算相似度（阈值0.3）智能决策是否启用联网模型，并在界面与日志中实时暴露路由依据，使得生成过程从黑盒变为白盒，满足了合规审计需求。

5.3 不足与后续改进

存在问题一是对扫描件PDF的支持不足，原因在于pypdf无法抽取无文本层PDF；改进方案为接入第三方OCR能力或升级视觉解析流程，优先级为高。存在问题二是顺序生成效率较低，长文档耗时明显，原因在于当前为顺序for循环且包含审核重试；改进方案为引入异步队列与并发生成机制，但需注意API限流，优先级为中。存在问题三是复杂合并单元格的表格索引偶发错位，原因在于LLM对复杂HTML/Word结构的JSON映射能力有限；改进方案为优化表格上下文提取逻辑，优先推荐用户使用锚点模板，优先级为中。

第6章 总结与反思

6.1 核心收获

通过本项目，我深刻理解了智能体应用中角色设定、工作流、数据库、知识库与插件调用之间的协同关系：角色设定是合规的底线约束，知识库是事实的源泉，数据库是状态与语料的持久化载体，工作流是编排调度的中枢，插件则是突破局部能力瓶颈的利翼。本项目最关键的技术突破在于实现了RAG与结构化回填的深度融合，使得大模型不再仅仅是对话框里的文本生成器，而是成为了能够操控企业级文档结构的实用工具。

6.2 最大挑战

开发过程中最大的挑战是处理Word表格的上下文融合与回填定位。大模型在生成表格单元格内容时，极易脱离上下文写出整段论述或跨格内容，且回填时合并单元格的行列索引极易偏移。最终我通过构建表格上下文提取器，将表头、行首列及邻格文本注入提示词，并在生成器内对表格格任务强制收紧字数上限，同时在后处理阶段增加表格可读性清洗逻辑，才较好地解决了这一问题。

6.3 未来展望

展望未来，智能体在办公与企业服务领域的前景广阔。如果继续开发，我计划引入批量并行生成能力以大幅缩短长文档生成时间，并增加自动合规裁决模块，将法务规则也沉淀为知识库，实现生成后的自动红绿灯警示。此外，还可以将系统拓展为多智能体协作模式，由资料管理员Agent、撰稿Agent、审核Agent分别角色扮演，进一步逼近真实的团队协作流程。

注:本文部分内容由AI生成,无法确保真实准确,仅供参考